概 率 论 通 俗 讲 义 · 详 解 版

贝叶斯概率与贝叶斯定理
从直觉、推导到工程应用

逐步推导 · 完整演算 · 工程实现，只需高中数学

$$P(H \mid E) = \frac{P(E \mid H)\,P(H)}{P(E)}$$

内容：条件概率 · 逐行推导 · 疾病筛查完整演算 · 垃圾邮件过滤 · 故障诊断 · 雷达检测 · A/B 测试

读者对象：具备高中数学基础的工程师、学生与自学者

2026 年 10 月

目　录

1　引言：为什么需要贝叶斯思维　3

2　概率的两种理解：频率学派与贝叶斯学派　4

3　从条件概率到贝叶斯定理（逐步推导）　5

3.1　条件概率：信息如何缩小可能性　5

3.2　乘法规则　6

3.3　全概率公式　7

3.4　贝叶斯定理：由结果追溯原因　8

3.5　先验、似然与后验　10

4　贝叶斯定理的完整演算示例　12

4.1　疾病筛查：一道题的完整七步　12

4.2　三门问题（蒙提霍尔悖论）　14

5　贝叶斯更新：证据如何改变信念　15

6　工程应用（计算与实现详解）　17

6.1　垃圾邮件过滤：朴素贝叶斯分类器　17

6.2　设备故障诊断与可靠性工程　20

6.3　雷达与信号检测　22

6.4　贝叶斯 A/B 测试与在线学习　23

6.5　更多应用一览与统一工作流　24

7　常见误区与注意事项　26

8　结语　27

附录 A　所需高中数学知识回顾　28

A.1　集合与事件　28

A.2　古典概型与概率的基本性质　28

A.3　计数原理：加法、乘法与排列组合　29

A.4　条件概率与事件的独立性　29

A.5　数学期望与方差（初步）　29

附录 B　练习题（附参考答案）　31

参考文献　32

1　引言：为什么需要贝叶斯思维

我们每天都在和"不确定性"打交道：天气预报说"明天降雨概率 70%"，体检报告说某项指标"呈阳性"，工程师说"这台设备在未来一年内发生故障的概率约为 2%"。这些说法背后都有一个共同的问题——**如何根据有限的信息，对一件不确定的事情做出尽可能合理的判断？**

贝叶斯方法给出的回答朴素而深刻：

> *先有一个初步的猜测（先验），然后每当获得新的证据，就用一条统一的公式修正这个猜测（得到后验）。证据越多，判断越准。*

这条公式就是**贝叶斯定理**（Bayes' theorem）。它由 18 世纪英国牧师托马斯·贝叶斯（Thomas Bayes）提出，经拉普拉斯（Laplace）系统化后，如今已成为人工智能、医学诊断、可靠性工程、金融风控等领域的核心工具。你每天收到的邮件之所以很少有垃圾邮件混入收件箱，背后就有它的功劳。

本文面向**具备高中数学基础**的读者。我们不预设任何大学数学知识：正文只用到四则运算、分数、比例和一点集合的概念；用到的少量高中概率知识（古典概型、排列组合、条件概率）都在附录 A 中有完整回顾。本详解版有两个写作原则：

- **推导不跳步**：每一条公式都从它的前一步严格推出，每步标明使用了哪条已有结论，并立即用具体数字验证；
- **例子算到底**：每个工程应用都从原始数据开始，一步一步算到最终决策，并给出工程实现的关键环节（含伪代码）。

> **阅读指南**
>
> 第 2 章建立直觉；第 3 章是全文的核心推导，每一节都是"直观例子 → 严格定义 → 数字验证"三步走；第 4 章用一道题做七步完整演算，检验你是否真的会用定理；第 5 章展示"连续更新"的贝叶斯工作方式；第 6 章进入工程实战。如果某处符号看不懂，请先查附录 A，再回到正文。

2　概率的两种理解：频率学派与贝叶斯学派

在深入公式之前，先澄清一个根本问题：**概率到底是什么？**对此历史上有两派观点，理解它们的区别是理解贝叶斯方法的前提。

2.1　频率学派：概率是长期频率的极限

频率学派认为，概率描述的是**可重复试验**中某个结果出现的长期频率。抛一枚均匀的硬币很多次，正面朝上的比例会趋近于 $1/2$，所以"正面朝上"的概率是 $1/2$。这是高中课本采用的定义，直观、客观，但它有一个明显的局限：**对于不能重复的事件，频率定义无能为力。**

例如："明天降雨的概率是 70%"——明天只有一次，不可能重复一万次；"这台设备今年内出故障的概率是 2%"——这台设备、今年，都是独一无二的情境。频率学派对此只能绕道而行，贝叶斯学派则直面这类问题。

2.2　贝叶斯学派：概率是信念的度量

贝叶斯学派认为，概率是对"我们对某件事相信到什么程度"的**量化度量**。它不要求事件可重复：

- "明天降雨概率 70%" = 根据现有气象信息，我们对"明天降雨"这件事的相信程度是 0.7；
- "设备今年故障概率 2%" = 综合设计数据、历史记录和使用环境，我们对"今年故障"的相信程度是 0.02。

更重要的是，贝叶斯学派认为**信念应当随证据更新**：早上看云图时认为降雨概率 70%，中午看到天边积雨云发展起来，就应上调到 90%；一阵风把云吹散了，就应下调。贝叶斯定理正是"如何更新"的精确规则——它告诉你，新证据出现后，相信程度应该调整到多少，**不多也不少**。

2.3　两派并不矛盾

两派使用同一套概率运算规则（加法规则、乘法规则等，见附录 A），分歧只在"概率的含义"。实际上，当数据足够多时，贝叶斯方法的后验会自动收敛到频率学派的答案（第 5 章的图 1 会直观展示这一点）。可以这样说：**贝叶斯方法把"学习"这件事本身变成了一种数学运算。**

3　从条件概率到贝叶斯定理（逐步推导）

本章是全文的数学核心。我们从"条件概率"这个最基本的概念出发，只用"分数的恒等变形"，一步步推出贝叶斯定理。每一节的结构相同：**先用一个可以数人数的具体例子建立直觉，再给出严格定义或定理，最后用同一组数字验证公式。**全程不需要任何超出高中的知识。

3.1　条件概率：信息如何缩小可能性

先看一个可以数人数的例子。某班有 40 名学生，性别与戴眼镜情况的统计如下表：

表 1　某班 40 名学生的性别与戴眼镜情况

	戴眼镜	不戴眼镜	合计
男生	6	18	24
女生	4	12	16
合计	10	30	40

随机抽一名学生。设事件 A="抽到戴眼镜的学生"，事件 B="抽到男生"。

第一问（无条件概率）：抽到戴眼镜学生的概率是多少？40 人中 10 人戴眼镜，由古典概型（附录 A.2）：

$$P(A) = \frac{10}{40} = \frac{1}{4} = 25\%.$$

第二问（条件概率）：如果告诉你"**抽到的是男生**"，在这个信息之下，戴眼镜的概率是多少？

关键是看清这条信息做了什么：**它把女生的 16 人从候选中排除了**。现在只需要在 24 名男生中考虑，其中 6 人戴眼镜，所以答案是

$$\frac{6}{24} = \frac{1}{4} = 25\%.$$

注意这个答案不是从公式算出来的，而是"只盯着表格的男生那一行"数出来的。**条件概率的全部秘密就是一句话：已知某事件发生，就把样本空间缩小到这个事件内部，再在新空间里数比例。**

但是"数人数"只在能列表格时方便。为了写成可推广的公式，把上面的数法改写成概率语言：6 是"既是男生又戴眼镜"的人数，即 $A \cap B$ 所含结果数；24 是 B 所含结果数；40 是总结果数。于是

$$\frac{6}{24} = \frac{6/40}{24/40} = \frac{P(A \cap B)}{P(B)}.$$

分子分母同除以 40，人数之比就变成了概率之比——这个恒等变形把我们引到正式定义：

> **定义 1（条件概率）**
>
> 设 A、B 是同一试验中的两个事件，且 $P(B)>0$。**在 B 已经发生的条件下，A 发生的概率**定义为
>
> $$P(A\mid B)\;=\;\frac{P(A\cap B)}{P(B)} \tag{3-1}$$
>
> 其中 $A\cap B$ 表示"A 与 B 同时发生"，读作"A 交 B"；$P(A\mid B)$ 读作"给定 B 时 A 的概率"。

用表 1 验证定义。$P(A\cap B)=6/40=0.15$（既是男生又戴眼镜），$P(B)=24/40=0.6$（男生），代入式 (3-1)：

$$P(A\mid B)=\frac{0.15}{0.6}=0.25=25\%.$$

与直接数人数的结果 $6/24=25\%$ 完全一致。这就是条件概率公式的来源与正确性：**它只是"在新样本空间里数比例"这件朴素事情的概率写法。**

> **条件概率与普通概率的本质区别**
>
> 普通概率 $P(A)$ 的"分母"是整个样本空间 Ω；条件概率 $P(A\mid B)$ 的"分母"是缩小后的样本空间 B。**新信息的作用就是缩小分母**。后文所有的贝叶斯计算，归根结底都是"分母换了一个又一个"。

3.2　乘法规则

式 (3-1) 中，$P(A\cap B)$ 在分子上。有时候我们恰恰想求它——比如"两件事同时发生"的概率。把式 (3-1) 两边同时乘以 $P(B)$（恒等变形），得到：

$$P(A\cap B)\;=\;P(A\mid B)\,P(B) \tag{3-2}$$

这叫**乘法规则**：两个事件同时发生的概率 = 其中一个事件的概率 × 在它发生的条件下另一个事件的概率。由于 $A\cap B$ 与 $B\cap A$ 是同一事件，乘法规则还可以对称地写成 $P(A\cap B)=P(B\mid A)\,P(A)$——3.4 节的推导会用到这个对称性。

例 1（不放回抽牌：两种算法互相验证）

从一副 52 张扑克牌中不放回地抽两张，求"两张都是 A"的概率。

方法一：乘法规则。设 B="第一张是 A"，A="第二张是 A"。第一张是 A 的概率 $P(B)=4/52$；在第一张已经是 A 的条件下，牌堆剩 51 张、A 剩 3 张，故 $P(A\mid B)=3/51$。由式 (3-2)：

$$P(A\cap B)=\frac{4}{52}\times\frac{3}{51}=\frac{12}{2652}=\frac{1}{221}\approx 0.452\%.$$

方法二：古典概型（附录 A.3）。52 张中任取 2 张共 $C_{52}^{2}=\frac{52\times 51}{2}=1326$ 种等可能结果；两张都是 A 的有 $C_{4}^{2}=6$ 种。故概率为 $\frac{6}{1326}=\frac{1}{221}$。

两种方法答案相同——这说明乘法规则没有引入任何新假设，它只是把"先抽第一张、再抽第二张"的分步计数换了个写法。

3.3　全概率公式

现在考虑一类新问题：**一个结果可以由多条"路径"导致，求这个结果的总概率。**

先用人数建立直觉。某工厂有甲、乙两条生产线。甲的产量占全厂 60%，产品不合格率 2%；乙的产量占 40%，不合格率 5%。随机抽一件产品，它不合格的概率是多少？

想象全厂共生产 10000 件产品（想象一个具体总数，计算就会变成小学算术）：

- 甲生产 $10000\times 60\%=6000$ 件，其中不合格 $6000\times 2\%=120$ 件；
- 乙生产 $10000\times 40\%=4000$ 件，其中不合格 $4000\times 5\%=200$ 件；
- 全厂不合格共 $120+200=320$ 件，所以抽到不合格品的概率为 $\frac{320}{10000}=3.2\%$。

把上面的算术改写成符号：设 B="抽到不合格品"，A_1="产品来自甲"，A_2="产品来自乙"。刚才算的就是

$$P(B)=\underbrace{2\%\times 60\%}_{P(B\mid A_1)\,P(A_1)}+\underbrace{5\%\times 40\%}_{P(B\mid A_2)\,P(A_2)}=0.032.$$

"按来源分情况、各情况加权求和"——这就是全概率公式。权重是各来源的占比 $P(A_i)$，被加权的是各来源下的不合格率 $P(B\mid A_i)$。

定理 1（全概率公式）

设 $A_1, A_2, \ldots, A_n$ 把样本空间切成互不重不漏的 n 块（即两两互斥、合起来覆盖全部可能，称为一个**划分**），且每块的概率都为正。则对任意事件 B：

$$P(B) \;=\; P(B \mid A_1)P(A_1) + P(B \mid A_2)P(A_2) + \cdots + P(B \mid A_n)P(A_n) \;=\; \sum_{i=1}^{n} \tag{3-3}$$

定理 1 的推导（四小步，每步注明依据）

第 1 步：把 B 按来源切开。因为 $A_1, \ldots, A_n$ 不重不漏地铺满整个样本空间，"B 发生"这件事必然是与某一个 A_i 一起发生的。所以 B 被恰好切成 n 小块：

$$B = (B \cap A_1) \cup (B \cap A_2) \cup \cdots \cup (B \cap A_n).$$

（依据：划分的定义——每个结果属于且只属于一个 A_i。）

第 2 步：各小块互斥，概率可加。由于 A_i 两两互斥，小块 $B \cap A_i$ 也两两互斥。互斥事件的概率等于各自概率之和（附录 A.2）：

$$P(B) = P(B \cap A_1) + P(B \cap A_2) + \cdots + P(B \cap A_n).$$

第 3 步：每一项用乘法规则改写。对每个 i，由式 (3-2)（交换 A、B 的角色）：$P(B \cap A_i) = P(B \mid A_i)\,P(A_i)$。

第 4 步：代入第 2 步。把第 3 步的每一项代进第 2 步的求和，即得式 (3-3)。证毕。

例 2（三条生产线，为下一节埋的伏笔）

三条生产线甲、乙、丙的产量分别占全厂的 50%、30%、20%，各自的不合格率为 1%、2%、5%。随机抽一件产品，它不合格的概率为

$$P(B) = 0.01 \times 0.5 + 0.02 \times 0.3 + 0.05 \times 0.2 = 0.005 + 0.006 + 0.010 = 0.021,$$

即全厂不合格率 2.1%。请记下这三个加数 0.005、0.006、0.010——下一节它们将直接变成答案的分子。

3.4　贝叶斯定理：由结果追溯原因

例 2 是"**由原因推结果**"：知道各产线情况，求不合格率。工程与生活中更常见的却是反过来——**由结果追溯原因**：

> *抽到的这件产品**已经确认不合格**，它最可能来自哪条生产线？*

先用人数据直算。想象 10000 件产品：甲产 5000 件、不合格 50 件；乙产 3000 件、不合格 60 件；丙产 2000 件、不合格 100 件。不合格品共 210 件。现在已知抽到的是不合格品（样本空间缩小到这 210 件！），它来自甲的概率是 $\frac{50}{210}\approx 23.8\%$，来自乙 $\frac{60}{210}\approx 28.6\%$，来自丙 $\frac{100}{210}\approx 47.6\%$。**尽管丙的产量最小，它却是最大的嫌疑来源**——因为它的不合格率最高。

贝叶斯定理就是把上面的"缩小样本空间数人数"写成一般公式。推导只需三步，每一步都是我们已经证明过的东西：

贝叶斯定理的推导（三步）

目标：求 $P(A_i \mid B)$，即"结果 B 已经发生，原因是 A_i"的概率。

第 1 步：对目标用条件概率定义。由式 (3-1)（把定义中的 A 换成 A_i）：

$$P(A_i \mid B)=\frac{P(A_i\cap B)}{P(B)}. \tag{*}$$

第 2 步：处理分子——用乘法规则。交事件与顺序无关：$P(A_i\cap B)=P(B\cap A_i)$；再由乘法规则 (3-2)（交换角色）：$P(B\cap A_i)=P(B\mid A_i)\,P(A_i)$。合起来：

$$P(A_i\cap B)=P(B\mid A_i)\,P(A_i).$$

代入 (*) 的分子：

$$P(A_i \mid B)=\frac{P(B\mid A_i)\,P(A_i)}{P(B)}. \tag{**}$$

第 3 步：处理分母——用全概率公式。分母 $P(B)$ 正是定理 1 的对象，用式 (3-3) 展开即可。证毕。

定理 2（贝叶斯定理）

设 $A_1,\dots,A_n$ 是样本空间的一个划分，$P(B)>0$。则对每个 i：

$$P(A_i \mid B) \;=\; \frac{P(B\mid A_i)\,P(A_i)}{\displaystyle\sum_{j=1}^{n} P(B\mid A_j)\,P(A_j)} \tag{3-4}$$

最常用的两情形版本：把假设记为 H，它的对立面记为 $\bar{H}$（"H 不成立"），证据记为 E，则

$$P(H \mid E) \;=\; \frac{P(E\mid H)\,P(H)}{P(E\mid H)\,P(H)+P(E\mid \bar{H})\,P(\bar{H})} \tag{3-5}$$

用例 2 的数字验证定理。取 $i=$ 甲：分子 $P(B\mid A_1)P(A_1)=0.01\times 0.5=0.005$（正是例 2 的第一个加数）；分母 $P(B)=0.021$（例 2 的答案）。于是

$$P(\text{甲}\mid B)=\frac{0.005}{0.021}\approx 23.8\%,$$

与数人数的结果 $50/210$ 完全一致。同理，$P(\text{乙}\mid B)=0.006/0.021\approx 28.6\%$，$P(\text{丙}\mid B)=0.010/0.021\approx 47.6\%$。**三个后验之和恰为 1**（$0.005+0.006+0.010=0.021$，分子之和等于分母）——这可以用来检查计算是否出错。

> **推导回顾：贝叶斯定理从哪里来**
>
> 整个推导只用到了三件东西：条件概率的定义（第 1 步）、乘法规则（第 2 步）、全概率公式（第 3 步）；而后两者又只是"互斥可加 + 条件概率定义"的推论。**贝叶斯定理没有任何神秘的假设，它是概率运算规则的直接推论。**真正有哲学分量的是它的**用法**（下一节），而不是它的证明。

3.5　先验、似然与后验

把式 (3-5) 中的符号换成有含义的名字。设 H 是我们关心的"假设"（Hypothesis，如"此人患病""此邮件是垃圾邮件"），E 是观测到的"证据"（Evidence，如"化验阳性""邮件含'中奖'一词"）。贝叶斯定理写成：

$$\underbrace{P(H\mid E)}_{\text{后验概率}}=\frac{\overbrace{P(E\mid H)}^{\text{似然}}\cdot\overbrace{P(H)}^{\text{先验概率}}}{\underbrace{P(E)}_{\text{证据的总概率}}} \tag{3-6}$$

表 2　贝叶斯定理各部分的含义与获取方式

名称	符号	含义	通常如何获得
先验概率	$P(H)$	看到证据之前，对假设的相信程度	历史统计、经验、领域知识
似然	$P(E\mid H)$	若假设为真，出现此证据的可能性	实验标定、设备参数、训练数据统计
证据概率	$P(E)$	证据出现的总概率（归一化常数）	由全概率公式自动算出

后验概率	$P(H \mid E)$	看到证据之后，对假设的修正相信程度	贝叶斯定理的计算结果

关于分母有一个能大幅简化计算的事实：**对同一个证据 E，无论比较哪个假设，分母 $P(E)$ 都一样。**所以比较多个假设时只需比较分子，写成

$$\text{后验} \ \propto \ \text{似然} \times \text{先验} \tag{3-7}$$

（$\propto$ 读作"正比于"），最后再把各假设的分子除以它们的总和做"归一化"，使概率之和为 1。

一句话总结：判断一件事时，贝叶斯方法强迫你同时回答两个问题：*这件事本身有多常见？*（先验）*如果它为真，看到眼前证据的可能性有多大？*（似然）。忽略任何一个，都会犯错——下一章的完整演算将生动地说明这一点。

4　贝叶斯定理的完整演算示例

本章做两件事：第一，把一道贝叶斯题从头到尾、分七步完整算一遍，每一步都说明"在做什么、为什么这么做"；第二，再用三门问题做一次换场景的练习。学完本章，你应当能独立解决任何"两假设 + 一份证据"的贝叶斯问题。

4.1　疾病筛查：一道题的完整七步

> **题目**
>
> 某疾病在人群中的患病率为 0.1%。有一种化验方法：患病者化验呈阳性的概率为 99%（灵敏度），健康者化验呈阳性的概率为 1%（误报率，即特异度 99%）。某人化验结果呈阳性，求他真正患病的概率。

第 1 步：把题目翻译成符号。这是最重要的半步。题目里有两个"角色"：

- 假设 H="此人患病"，对立面 $\bar{H}$="此人健康"；
- 证据 E="化验阳性"。

题目要求的"阳性者真正患病的概率"，符号写法是 $P(H \mid E)$——**已知证据、求假设**，方向是从结果（阳性）追溯原因（患病），这正是贝叶斯定理的形状。

第 2 步：把题目给出的三个数对号入座。

表 3　题目条件的符号化

题目原话	符号	数值	角色
患病率 0.1%	$P(H)$	0.001	先验
（健康占剩下全部）	$P(\bar{H}) = 1 - P(H)$	0.999	先验的对立
患病者阳性率 99%	$P(E \mid H)$	0.99	似然（真阳性）
健康者阳性率 1%	$P(E \mid \bar{H})$	0.01	似然（假阳性）

注意一个常见陷阱：题目给的全是 $P(\text{证据} \mid \text{假设})$ 方向的条件概率，而要求的是反方向的 $P(\text{假设} \mid \text{证据})$——**方向相反，正是需要贝叶斯定理而不是直接读数的信号。**

第 3 步：写出公式。用两情形版本 (3-5)：

$$P(H \mid E) = \frac{P(E \mid H)\,P(H)}{P(E \mid H)\,P(H) + P(E \mid \bar{H})\,P(\bar{H})} \tag{4-1}$$

第 4 步：算分子（真阳性贡献）。

$$P(E \mid H)\,P(H) = 0.99 \times 0.001 = 0.00099.$$

含义：人群中"既患病又化验阳性"的比例。一万人里约 10 人患病，其中约 9.9 人化验阳性。

第 5 步：算分母的第二项（假阳性贡献）。

$$P(E \mid \bar{H})\,P(\bar{H}) = 0.01 \times 0.999 = 0.00999.$$

含义：人群中"健康却被误报阳性"的比例。一万人里约 9990 人健康，其中约 99.9 人被误报。**注意：假阳性贡献 (0.00999) 是真阳性贡献 (0.00099) 的十倍**——结果还没算完，胜负已现。

第 6 步：相除，得出后验。

$$P(H \mid E) = \frac{0.00099}{0.00099 + 0.00999} = \frac{0.00099}{0.01098} \approx 0.0902 \approx 9\%.$$

化验呈阳性的人，真正患病的概率只有约 9%。尽管化验"99% 准确"。

第 7 步：交叉验证与合理性检查。任何概率计算都应做一次独立验证。用"万人表格法"——把概率换成人数填表：

表 4　10000 人筛查的期望人数分布（交叉验证用）

	化验阳性 E	化验阴性 $\bar{E}$	合计
患病 H（10000×0.1% = 10 人）	10×99% ≈ 9.9	0.1	10
健康 $\bar{H}$（9990 人）	9990×1% ≈ 99.9	9890.1	9990
合计	**109.8**	9890.2	10000

阳性共 109.8 人，其中真患病 9.9 人：$9.9/109.8 \approx 9.02\%$，与第 6 步完全一致。再检查合理性：后验 9% 介于先验 0.1% 与 100% 之间（证据把怀疑度抬高了约 90 倍，但远没到"确诊"），方向与幅度都合乎情理。

> **为什么会这么低？——基数（先验）的力量**
>
> 疾病太罕见（先验 0.1%），导致即使误报率只有 1%，庞大的健康人群（9990 人）贡献的假阳性（99.9 人）也远远超过微小的患病人群（10 人）贡献的真阳性（9.9 人）。**当假设很罕见时，再准确的单一证据也不足以直接"定罪"。**这也是医学上"筛查阳性后必须做进一步确诊检查"的数学原因。

追加一步：第二次化验（序贯更新的预告）。假设对同一人再做一次**相互独立**的同种化验，结果仍为阳性。这次把第一次的后验 9.02% 当作新先验，重复第 4〜6 步：

$$\text{分子} = 0.99 \times 0.0902 \approx 0.0893; \qquad \text{分母第二项} = 0.01 \times (1 - 0.0902) \approx 0.00910;$$
$$P(H \mid E_1, E_2) = \frac{0.0893}{0.0893 + 0.00910} \approx 0.908 \approx 91\%.$$

两次独立阳性后，后验从 0.1% 升至约 91%——"复查"之所以是标准流程，原因就在这里。第 5 章会把这种"后验变先验"的更新方式一般化。

4.2　三门问题（蒙提霍尔悖论）

综艺节目中有三扇门，一扇后面是汽车，另两扇后面是山羊。你选了 1 号门。主持人（他知道车在哪）打开 3 号门，里面是山羊。主持人问："要不要改选 2 号门？"

直觉说：剩两扇门，换不换都是 1/2。**正确答案是：换，中奖概率从 1/3 升到 2/3。**用上一节的七步流程走一遍：

第 1〜2 步（符号化与已知量）。令 C_i="车在 i 号门后"。没有任何信息时 $P(C_1) = P(C_2) = P(C_3) = 1/3$（先验）。证据 E="主持人打开 3 号门（且是山羊）"。似然由主持人的规则"必须开一扇你没选的、有山羊的门"决定：

- 若车在 1 号（C_1）：2、3 号都是山羊，主持人随机挑一扇，$P(E \mid C_1) = 1/2$；
- 若车在 2 号（C_2）：主持人只能开 3 号，$P(E \mid C_2) = 1$；
- 若车在 3 号（C_3）：主持人不能开 3 号，$P(E \mid C_3) = 0$。

第 3〜5 步（算分母，全概率公式）。

$$P(E) = \tfrac{1}{2} \cdot \tfrac{1}{3} + 1 \cdot \tfrac{1}{3} + 0 \cdot \tfrac{1}{3} = \tfrac{1}{2}.$$

第 6 步（分别求后验）。不换（车在 1 号）：

$$P(C_1 \mid E) = \frac{(1/2)(1/3)}{1/2} = \frac{1}{3};$$

换（车在 2 号）：

$$P(C_2 \mid E) = \frac{1 \cdot (1/3)}{1/2} = \frac{2}{3}.$$

第 7 步（检查）。$\frac{1}{3} + \frac{2}{3} + 0 = 1$ ✓。

直觉解释：主持人的开门动作不是随机的——他"被迫"避开了有车的那扇门，这一行为本身携带了信息。你最初的选择有 1/3 的机会正确、2/3 的机会错误；主持人的动作不会动摇你最初选择的先验（无论车在不在 1 号后，他总能开一扇山羊门），但把剩下 2/3 的概率全部"压缩"到了他没开的那扇门上。

5　贝叶斯更新：证据如何改变信念

前两章是"一次性"的推断：看到一份证据，算一次后验。贝叶斯方法真正的威力在于**连续更新**：今天的后验，就是明天的先验。

5.1　序贯更新的规则

设先后获得两份相互独立（附录 A.4）的证据 E_1、E_2。第一步用 E_1 更新：

$$P(H \mid E_1) = \frac{P(E_1 \mid H)\,P(H)}{P(E_1)}.$$

第二步把 $P(H \mid E_1)$ 当作新的先验，用 E_2 再更新一次：

$$P(H \mid E_1, E_2) = \frac{P(E_2 \mid H)\,P(H \mid E_1)}{P(E_2)}$$

可以证明：只要证据相互独立，"一条条更新"与"把所有证据放在一起一次算"的结果完全相同。4.1 节的"两次化验"就是这个规则的实际操作。该性质在工程上极其有用——传感器数据是一条条来的，系统无需存储全部历史，只需保存当前的后验。(5-1)

5.2　数值示例：这枚硬币偏心吗？

一枚硬币，正面朝上的概率 θ 未知（可能被动过手脚）。我们的目标是根据抛掷结果逐步修正对 θ 的判断。这里 θ 是连续量，先验不再是一个数，而是一条**概率密度曲线**——它描述"我们认为 θ 落在各处的可能性有多大"（连续随机变量的直观解释见附录 A.5）。

采用工程中常用的做法：取先验为 Beta 分布 $\mathrm{Beta}(2,2)$——一条中间高、两头低、关于 0.5 对称的曲线，表示"倾向认为硬币公平，但不太确定"。Beta 分布有个漂亮的性质：观测到 h 次正面、t 次反面后，后验仍然是 Beta 分布，参数变为 $(2+h,\ 2+t)$——**更新规则就是简单的"计数相加"**。

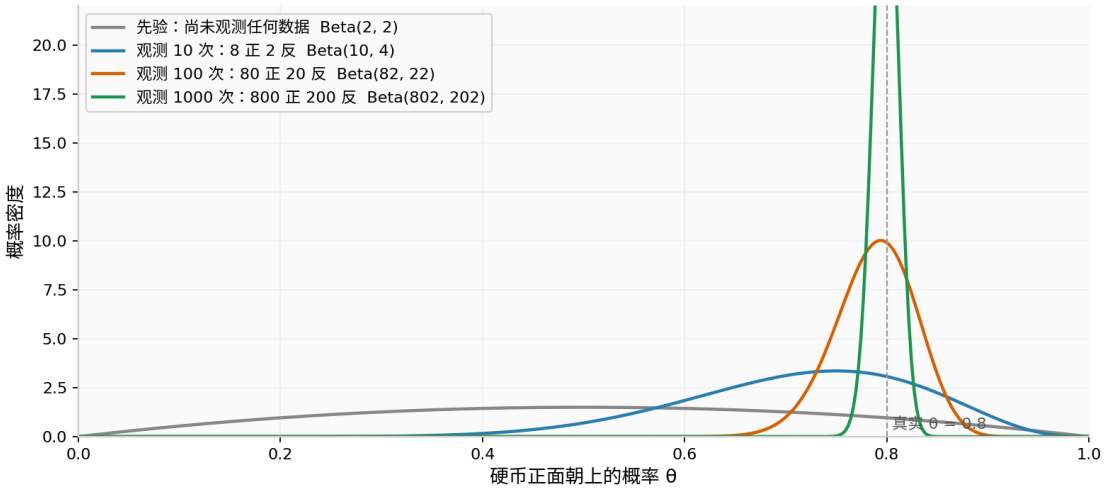


图 1　贝叶斯序贯更新：随着抛掷数据增多，后验分布越来越窄，并向真实值 θ = 0.8 收缩

图 1 中四条曲线对应四个时刻。可以看到三个规律：

- **起点宽容**：没有数据时（灰色曲线），θ 在 0.3～0.7 之间都有相当的合理性；
- **数据为王**：数据从 10 次增加到 1000 次，曲线的峰值被数据"拉"向真实值 0.8，先验的影响被逐渐冲淡；
- **越来越自信**：曲线越来越窄，意味着不确定性（方差，附录 A.5）越来越小。1000 次观测后，我们几乎可以肯定 θ 在 0.78～0.82 之间。

> **工程含义**
>
> 图 1 解释了为什么"贝叶斯方法在小样本时依赖先验、在大样本时依赖数据"。这也给出了一个实用准则：**先验可以主观，但只要证据持续积累，不同起点的观察者最终会殊途同归**——这正是科学共识形成的数学模型。6.4 节的 A/B 测试用的就是同一套"Beta 分布 + 计数相加"机制。

6　工程应用（计算与实现详解）

本章展示贝叶斯定理在四个典型工程场景中的完整用法。每个场景都按同一条主线展开：**问题与假设 → 数据如何变成先验与似然（标定） → 一步一步算到决策 → 工程实现要点（含伪代码）**。所有数字都可以用纸笔复算。

6.1　垃圾邮件过滤：朴素贝叶斯分类器

6.1.1　问题与整体思路

任务：给定一封邮件的内容，判断它是垃圾邮件（S）还是正常邮件（$\bar{S}$）。贝叶斯的做法是把邮件拆解成"词"这个粒度的证据：每个词的出现与否都是一份小证据，用式 (3-7) 把所有词的证据累积起来，最后比较

$$\frac{P(S \mid \text{邮件内容})}{P(\bar{S} \mid \text{邮件内容})} \gtrless 1,$$

大于 1 判垃圾邮件，小于 1 放行（阈值可调，见后）。问题归结为两件事：**先验与似然从哪里来**（训练），以及**面对一封新邮件怎么算**（判决）。

6.1.2　训练：从语料数出先验与似然（完整演算）

假设我们有一小份人工标注好的训练语料：8 封邮件，其中 4 封垃圾、4 封正常。只考虑词表 {免费， 中奖， 会议， 发票} 四个特征词。逐封统计后得到计数表：

表 5　训练语料的词频计数（8 封邮件）

特征词	在 4 封垃圾邮件中出现次数	在 4 封正常邮件中出现次数
免费	3	0
中奖	2	0
会议	0	3
发票	1	1

先验直接由比例给出：$P(S) = 4/8 = 0.5$，$P(\bar{S}) = 0.5$。

似然本应也是比例，如 $P(\text{免费} \mid S) = 3/4$。但有一个必须处理的工程问题：词"免费"在正常邮件中出现了 0 次，若直接取 $P(\text{免费} \mid \bar{S}) = 0/4 = 0$，那么任何含"免费"的正常邮件都会被判死（后验比中出现除以 0）。这叫**零概率灾难**。标准对策是**拉普拉斯平滑**（加一平滑）：给每个词的计数都加 1，分母相应加 2（"出现/不出现"两种取值）：

$$P(w \mid S) = \frac{\text{垃圾邮件中含 } w \text{ 的封数} + 1}{\text{垃圾邮件总封数} + 2}, \qquad P(w \mid \bar{S}) \text{ 同理} \tag{6-1}$$

逐个词算出（保留三位小数）：

表 6　平滑后的条件概率表（似然表）

词 w	$P(w \mid S)$	$P(w \mid \bar{S})$	$P(\bar{w} \mid S) = 1 - P(w \mid S)$	$P(\bar{w} \mid \bar{S})$
免费	$(3+1)/6 = 0.667$	$(0+1)/6 = 0.167$	0.333	0.833
中奖	$(2+1)/6 = 0.500$	$(0+1)/6 = 0.167$	0.500	0.833
会议	$(0+1)/6 = 0.167$	$(3+1)/6 = 0.667$	0.833	0.333
发票	$(1+1)/6 = 0.333$	$(1+1)/6 = 0.333$	0.667	0.667

平滑让每个概率都不为零，同时保留了大趋势（"免费"仍强烈偏向垃圾邮件，"发票"则不含区分信息）。至此训练完成：**所谓模型，就是这张表加一个先验**。

6.1.3　判决：一封新邮件的完整计算

来了一封新邮件，经分词发现：**含"免费"、含"中奖"、不含"会议"、不含"发票"**。要算 $P(S \mid \text{这封邮件})$。

第 1 步：朴素假设。直接统计"四个词某种组合出现的概率"需要 $2^4 = 16$ 种组合的样本，词表上千时根本统计不完。**朴素贝叶斯假设**：在给定邮件类别的条件下，各词出现与否相互独立（附录 A.4），于是联合概率拆成单词概率的乘积：

$$P(W_1, \ldots, W_n \mid S) = \prod_{i=1}^{n} P(W_i \mid S) \tag{6-2}$$

这个假设"朴素"得近乎天真（词语之间显然不独立，"免费"和"中奖"常一起出现），但实践证明它在分类任务上出奇地好——因为我们只关心哪一类的后验更大，而不需要概率的绝对值精确。

第 2 步：写后验比。对两类各用一次贝叶斯定理（式 3-7），分母 $P(\text{邮件})$ 相同，相比时约去：

$$\frac{P(S \mid W_1,\dots,W_n)}{P(\bar{S} \mid W_1,\dots,W_n)} = \underbrace{\frac{P(S)}{P(\bar{S})}}_{\text{先验比}} \cdot \prod_{i=1}^{n} \underbrace{\frac{P(W_i \mid S)}{P(W_i \mid \bar{S})}}_{\text{每个词的证据权重}} \tag{6-3}$$

第 3 步：逐项查表代入。先验比 $= 0.5/0.5 = 1$；四个证据项依次是：

- 含"免费"：$0.667/0.167 \approx 4.0$；
- 含"中奖"：$0.500/0.167 \approx 3.0$；
- 不含"会议"：用表 6 的"不出现"列，$0.833/0.333 \approx 2.5$；
- 不含"发票"：$0.667/0.667 = 1.0$（无信息，不出所料）。

第 4 步：连乘得后验比。

$$\frac{P(S \mid \cdot)}{P(\bar{S} \mid \cdot)} = 1 \times 4.0 \times 3.0 \times 2.5 \times 1.0 = 30.$$

第 5 步：换算回概率并判决。由 $P(S \mid \cdot) + P(\bar{S} \mid \cdot) = 1$ 得

$$P(S \mid \cdot) = \frac{30}{30+1} \approx 96.8\% > 1/2 \quad \Rightarrow \quad \text{判为垃圾邮件，移入垃圾箱。}$$

6.1.4　工程实现要点

数值稳定：取对数。真实邮件有几百个词，式 (6-3) 是几百个小于 1 的数连乘，会迅速下溢成 0。工程上取对数把连乘变连加：

$$\log \frac{P(S \mid \cdot)}{P(\bar{S} \mid \cdot)} = \log \frac{P(S)}{P(\bar{S})} + \sum_{i=1}^{n} \log \frac{P(W_i \mid S)}{P(W_i \mid \bar{S})} \tag{6-4}$$

用本节数据验证：$\log 1 + \log 4 + \log 3 + \log 2.5 + \log 1 \approx 0 + 1.386 + 1.099 + 0.916 + 0 = 3.40$，而 $e^{3.40} \approx 30$，与第 4 步一致。对数化后，每个词相当于一个可加可减的"分值"，过滤器就是一张词→分值表，判决就是查表求和——这正是其速度快、可部署在极大规模系统上的原因。

参考伪代码：

```
# ---------- 训练 ----------
for 邮件 in 训练集:
    类别 = 邮件.标注                          # S 或 非S
    类别计数[类别] += 1
    for 词 in 去重(分词(邮件)):
        词计数[类别][词] += 1
先验log比 = log(类别计数[S] / 类别计数[非S])
# 平滑后的对数似然比表
for 词 in 词表:
    分值[词] = log((词计数[S][词]+1) / (类别计数[S]+2))
             - log((词计数[非S][词]+1) / (类别计数[非S]+2))

# ---------- 判决 ----------
score = 先验log比
for 词 in 去重(分词(新邮件)):
    score += 分值.get(词, 平滑默认值)
if score > log(判决阈值):     # 阈值常取 9 而非 1，减少误伤正常邮件
    判为垃圾邮件
```

在线更新。用户每次点击"举报垃圾邮件"或"这不是垃圾邮件"，就是一条新标注样本：把对应词计数加一，分值表重新计算即可——这正是第 5 章序贯更新（今天的后验 = 明天的先验）的工程形态，过滤器因此越用越准。

阈值与代价。误判正常邮件进垃圾箱（误伤）的代价远高于放进一封垃圾邮件，故实际系统把判决阈值从 1 提高到 9 甚至更高（即后验超过约 90% 才拦截），阈值由业务代价决定——6.3 节会把这个思想一般化。

6.2　设备故障诊断与可靠性工程

6.2.1　问题与数据标定

工厂里一台关键泵机配有振动、温度两只传感器。任务：根据传感器信号，实时判断"泵机轴承是否磨损"，并给出分级处置。三个输入数据来自历史记录与设备手册（这一步叫**标定**，是贝叶斯工程的实地工作）：

- **先验** $P(H)=0.02$：该型号泵机年故障率约 2%（H="轴承磨损"）；
- **振动传感器** E_1：检出率 $P(E_1 \mid H)=0.95$，误报率 $P(E_1 \mid \bar{H})=0.05$；
- **温度传感器** E_2：检出率 $P(E_2 \mid H)=0.90$，误报率 $P(E_2 \mid \bar{H})=0.08$，与 E_1 相互独立（不同类型、不同物理原理的传感器，独立性近似成立）。

6.2.2　完整计算：报警后会发生什么（三种情形都算到底）

情形一：振动传感器报警。用式 (3-5)：

$$P(H \mid E_1) = \frac{0.95 \times 0.02}{0.95 \times 0.02 + 0.05 \times 0.98} = \frac{0.019}{0.019 + 0.049} = \frac{0.019}{0.068} \approx 27.9\%.$$

不到三成——与 4.1 节的医学筛查完全同构：罕见事件 + 单一证据，后验注定不高。

情形二：振动报警后，温度传感器也异常（第二份独立证据）。用序贯更新 (5-1)，新先验取 27.9%：

$$P(H \mid E_1, E_2) = \frac{0.90 \times 0.279}{0.90 \times 0.279 + 0.08 \times (1 - 0.279)} = \frac{0.251}{0.251 + 0.0577} \approx 81.3\%.$$

情形三：振动报警，但温度传感器正常。注意"正常"也是证据：此时用 $P(\bar{E}_2 \mid H) = 1 - 0.90 = 0.10$ 与 $P(\bar{E}_2 \mid \bar{H}) = 1 - 0.08 = 0.92$：

$$P(H \mid E_1, \bar{E}_2) = \frac{0.10 \times 0.279}{0.10 \times 0.279 + 0.92 \times 0.721} = \frac{0.0279}{0.0279 + 0.663} \approx 4.0\%.$$

同一只振动报警，因第二份证据方向不同，后验一个冲到 81%、一个跌回 4%。**证据是双向起作用的**——这正是"多传感器融合"的数学实质。

6.2.3　从后验到决策：分级门限

工程系统的正确姿势不是"报警即停机"，而是**按后验分级处置**，门限由代价权衡确定：

表 7　故障诊断的分级处置策略（示例门限）

后验 $P(H \mid \cdot)$ 区间	本文示例落点	处置动作	理由
低于 5%	情形三：4.0%	记录事件，继续观察	大概率误报，停机损失不值得
5%～80%	情形一：27.9%	触发人工复检 / 调取第二传感器	证据不足，需收集更多证据
高于 80%	情形二：81.3%	停机检修	继续运行的预期损失超过停机损失

6.2.4　工程实现要点

标定：检出率与误报率来自历史数据——统计过去 5 年"故障发生前传感器是否报警"与"无故障时是否误报"的记录，频率即概率的估计。**在线更新：**传感器数据流式到达，系统只需保存当前后验一个数，每条新数据做一次式 (5-1) 的乘法，存储与计算量都极小。参考伪代码：

```
后验 = 0.02                        # 先验
loop 每收到一路传感器读数:
    (检出率, 误报率) = 查该传感器的标定表
    if 读数异常:  似然比 = 检出率 / 误报率
    else:          似然比 = (1-检出率) / (1-误报率)
    后验 = (后验 * 似然比) / (后验 * 似然比 + (1-后验))    # 式(3-5)的紧凑写法
    按表 7 的门限触发相应动作
```

现代预测性维护系统正是这样把多源传感器数据流式地喂给贝叶斯更新器，在"误停机损失"与"漏检事故损失"之间找到最优平衡。

6.3　雷达与信号检测

6.3.1　问题：两种错误，代价悬殊

雷达接收机收到的回波永远混着噪声。判决问题：H_1="目标存在"，H_0="目标不存在"。两类错误代价完全不同：**漏报**（有目标报无）可能酿成事故；**虚警**（无目标报有）只是浪费一次核实资源。贝叶斯判决的思想是：**门限不由"概率是否过半"决定，而由两种错误的代价之比决定。**

6.3.2　数据标定与完整计算

为让计算只需小学算术，把回波强度离散化为三档：弱、中、强。标定数据（由已知目标的试飞试验与纯噪声时段的统计得到）如下：

表 8　回波强度在两种情形下的分布（标定结果）

回波强度	$P(\cdot \mid H_1)$ 目标存在	$P(\cdot \mid H_0)$ 纯噪声	似然比 $P(\cdot \mid H_1)/P(\cdot \mid H_0)$
弱	0.10	0.70	0.143
中	0.30	0.25	1.2
强	0.60	0.05	**12**

先验：该空域绝大多数时刻没有目标，$P(H_1)=0.001$，$P(H_0)=0.999$。代价：漏报一次记 $C_{\text{漏报}}=100$，虚警一次记 $C_{\text{虚警}}=1$。

判决规则的推导（一句话版本）：比较两种判决的期望代价，可以推出等价形式——当后验比超过门限 $C_{\text{虚警}}/C_{\text{漏报}}$ 时判有目标（期望代价的比较见附录 A.5 的期望概念）：

$$\frac{P(H_1 \mid x)}{P(H_0 \mid x)} = \underbrace{\frac{P(x \mid H_1)}{P(x \mid H_0)}}_{\text{似然比}} \cdot \frac{P(H_1)}{P(H_0)} \quad > \quad \frac{C_{\text{虚警}}}{C_{\text{漏报}}} = \frac{1}{100} = 0.01 \quad \Rightarrow \quad \text{判目标存在} \tag{6-5}$$

情形一：收到"强"回波。似然比 $= 12$，后验比 $= 12 \times \frac{0.001}{0.999} \approx 0.0120$。比较门限：$0.0120 > 0.01$ ——**判目标存在**，引导核实或拦截程序。

情形二：收到"中"回波。似然比 $= 1.2$，后验比 $\approx 1.2 \times 0.001001 \approx 0.0012 < 0.01$ ——判无目标，继续监视。

情形三：收到"弱"回波。后验比 $\approx 0.143 \times 0.001 \approx 0.00014$，强烈支持无目标。

对照实验：若两种错误代价相同（门限 = 1）。情形一的后验比 0.012 远小于 1，会判"无目标"——同一数据、不同代价，决策相反。还可以换算成概率：情形一的后验 $P(H_1 \mid \text{强}) = \frac{0.0120}{1+0.0120} \approx 1.19\%$。**注意：判决"有目标"并不等于"很可能有目标"**——只有 1.19%！但因为漏报代价是虚警的 100 倍，"宁可九十九次虚警、不可一次漏报"是期望代价最小的选择。防空预警把门限调低、民航监视把门限调高，区别全在代价。

6.3.3　工程实现要点

标定：表 8 的两列分布来自外场试验——让已知目标在不同距离飞行，统计回波强度直方图；再在确认无目标的时段统计噪声直方图。**实时判决：**接收机每收到一个回波，查表取似然比，乘上先验比，与门限比较——三次算术运算，微秒级完成，这就是贝叶斯判决在雷达中用了大半个世纪的原因。**与工程惯例的关系：**雷达工程中的"恒虚警率（CFAR）处理"可以理解为自动估计噪声分布 $P(x \mid H_0)$ 的模块，与本节框架完全兼容。通信中的最佳接收机、医学影像的病灶检测，判决结构与此完全相同。

6.4　贝叶斯 A/B 测试与在线学习

6.4.1　问题与数据

某产品要改版按钮：旧版 A 展示 1000 次、点击 120 次；新版 B 展示 1000 次、点击 150 次。问题：**B 的点击率 θ_B 高于 A 的 θ_A 的把握有多大？现在全量切换，选错的代价是多大？**

6.4.2　完整计算

第 1 步：建模。对每个版本的点击率各维护一个 Beta 分布（与 5.2 节硬币例同机制）：先验取均匀分布 $\mathrm{Beta}(1,1)$（表示事前一无所知），观测到 c 次点击、$n-c$ 次未点击后，后验为 $\mathrm{Beta}(1+c,\ 1+n-c)$。

第 2 步：写出后验。

$$\theta_A \mid \text{数据} \sim \mathrm{Beta}(121,\,881), \qquad \theta_B \mid \text{数据} \sim \mathrm{Beta}(151,\,851).$$

第 3 步：后验均值（点估计）。Beta 分布 $\mathrm{Beta}(\alpha,\beta)$ 的均值为 $\alpha/(\alpha+\beta)$：

$$\hat{\theta}_A = \frac{121}{1002} \approx 12.08\%, \qquad \hat{\theta}_B = \frac{151}{1002} \approx 15.07\%.$$

第 4 步：算"B 更好"的概率。该概率没有简单的纸笔公式，工程上用蒙特卡洛模拟：从两个后验中各随机抽 100 万个样本，逐对比较大小——模拟结果为

$$P(\theta_B > \theta_A \mid \text{数据}) \approx 97.5\%.$$

第 5 步：算"选错的期望损失"。若现在全量上线 B 而实际 A 更好，平均每次展示损失的点击率是 $E[\max(\theta_A-\theta_B,0)]$，同一批模拟样本给出的估计约为 **0.015%**（即万分之一点五）；反之若选 A，期望损失 $E[\max(\theta_B-\theta_A,0)] \approx 3.0\%$——相差约 200 倍。

第 6 步：决策。业务准则是"P(新版更好) 超过 95% 且选错的期望损失低于 0.05%"：两个条件都满足（97.5% > 95%，0.015% < 0.05%），**停止实验，全量上线 B**。

6.4.3　工程实现要点

流式更新：每来一批展示数据，只需给两个 Beta 参数加上"点击数、未点击数"（计数相加，同 5.2 节），无需保存原始日志。**与传统方法的区别：**频率学派的假设检验要预先定死样本量、中途看数会破坏 p 值的含义；贝叶斯方法的后验随时有效，"随时看数、随时决策"是它的结构性优势，在样本宝贵的场景（医疗试验、小流量产品）尤其重要。参考伪代码：

```
αA, βA = 1, 1;  αB, βB = 1, 1        # 均匀先验
loop 每批数据:
    αA += A点击数;  βA += A未点击数    # 后验 = 先验 + 计数
    αB += B点击数;  βB += B未点击数
    p   = 蒙特卡洛比较(αA, βA, αB, βB)   # P(θB > θA)
    损失 = 模拟均值(max(θA - θB, 0))
    if p > 0.95 and 损失 < 0.0005:
        停止实验, 全量上线 B
```

6.5　更多应用一览与统一工作流

表 9　贝叶斯方法在各工程领域的典型应用

领域	假设 H	证据 E	贝叶斯的作用
医学诊断	患某病	症状、化验结果	筛查阳性后的确诊概率，决定是否进一步检查

自动驾驶	前方有行人	摄像头、雷达、激光雷达数据	多传感器融合，持续更新障碍物的存在概率与位置
语音识别 / 机器翻译	某句话 / 某种译文	声学信号 / 源语言句子	在"语言模型先验"与"声学/翻译似然"间求最优解
金融风控	该交易是欺诈	金额、地点、设备指纹、行为序列	实时计算欺诈后验，决定拦截或放行
结构健康监测	桥梁出现损伤	应变、加速度传感器数据	融合历史巡检（先验）与实时监测，评估损伤概率
定位与导航	机器人 / 车辆的位置	GPS、惯导、地图匹配	贝叶斯滤波（卡尔曼滤波、粒子滤波的理论根基）
软件调试	缺陷在某个模块	测试失败日志、代码变更记录	缩小可疑代码范围，优先排查后验最高的模块

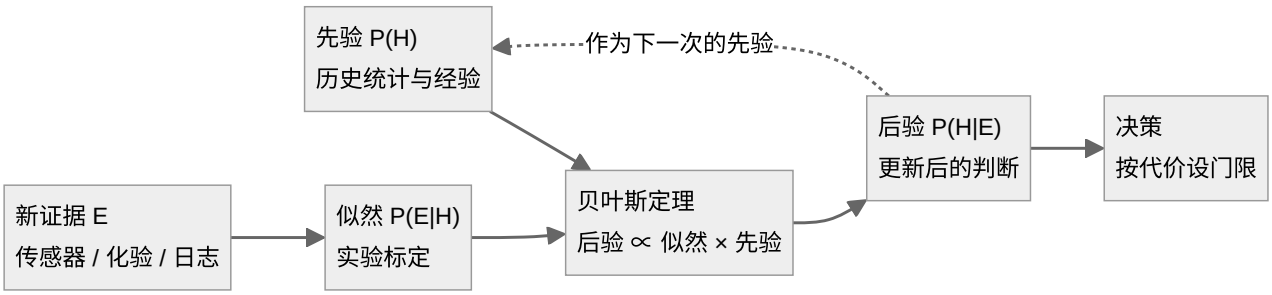


图 2　贝叶斯工程的统一工作流：先验与似然合成后验，后验驱动决策，并成为下一轮的先验

回顾本章四个场景，尽管领域迥异，工程结构却完全一致：**先验来自历史统计，似然来自标定试验，后验按式 (3-5) 计算，决策门限按代价设定，后验再作为下一轮的先验**。掌握这个循环，就掌握了贝叶斯工程的骨架。

7　常见误区与注意事项

7.1　混淆 $P(E \mid H)$ 与 $P(H \mid E)$

"化验的准确率 99%"是 $P(E \mid H)$（患病者检出率），而病人真正关心的是 $P(H \mid E)$（阳性者患病率）。4.1 节说明两者可以相差悬殊——一个是 99%，一个是 9%。**法庭上"在被告人住处发现的痕迹与现场一致的概率"与"现场痕迹来自被告的概率"也是同样的一对**，混淆它们曾造成多起著名冤案，被称为"检察官谬误"。写公式前先问自己：已知的是哪个方向？要求的是哪个方向？

7.2　忽视先验（基数谬误）

只看证据的强度（似然），不看事件的稀有程度（先验），是贝叶斯新手最常犯的错。万分之一发生率的罕见事件，即使证据"十倍倾向于它"，后验也只有约千分之一（6.3 节情形一的后验 1.19% 就是实例）。反过来，先验也不能脱离证据独断一切——图 1 显示，只要证据持续积累，后验终将被数据主导。**健康的贝叶斯实践是：诚实记录先验的来源，并随着证据更新它。**

7.3　独立性假设的滥用

6.1 节的朴素贝叶斯假设各词独立、6.2 节的两个传感器独立——这些假设只为计算方便而设。若证据实际强相关（如两个同型号、同安装的传感器会一起受电磁干扰），重复更新会**把同一份信息算了两次**，导致过度自信的后验。工程对策：尽量选物理上独立的证据源，或用相关性建模（协方差、贝叶斯网络）代替朴素假设。

7.4　把概率当成"确定无疑"

6.1 节后验 96.8% 的邮件仍有 3.2% 是误判。贝叶斯方法给出的不是"答案"，而是"当前证据下最优的相信程度"。工程系统的最后一道防线，永远是像 6.2、6.3 节那样**用代价决定行动门限**，而不是盲目相信任何单个数字。

8　结语

回顾全文，贝叶斯方法的骨架异常简洁：

- **一条公式**：后验 $\propto$ 似然 $\times$ 先验（式 3-6），由条件概率的定义三步推出，不含任何超纲内容；
- **一种姿态**：承认初始判断不完备（先验），承诺随证据修正（更新），并对"有多确定"给出量化回答（后验）；
- **一套工作流**：定义假设、标定似然、计算后验、按代价决策、用后验当新先验（图 2），在垃圾邮件过滤、故障诊断、雷达检测、A/B 测试中反复出现。

贝叶斯定理的数学只值半页纸，但它所编码的思想——**信念应当是可证伪、可更新、可量化的**——是工程师和科学工作者面对不确定性时最有力的思维工具之一。建议读者合上本文后，亲手把第 4 章的七步流程在附录 B 的习题上走一遍：纸笔之间，公式才会真正变成直觉。

附录 A　所需高中数学知识回顾

本附录回顾正文用到的全部预备知识，供需要查漏补缺的读者随时翻阅。各部分与正文章节的对应关系已在标题后注明。

A.1　集合与事件（对应 3.1 节）

集合是一些对象的全体，常用 A, B 表示。两个基本运算：

- **交** $A \cap B$：既在 A 中又在 B 中的元素（"A 且 B"）；
- **并** $A \cup B$：在 A 中或在 B 中（或两者都在）的元素（"A 或 B"）。

若 $A \cap B$ 为空集 $\varnothing$（没有公共元素），称 A、B **互斥**（互不相容）。

在概率论里，一次随机试验的所有可能结果组成**样本空间** Ω，它的子集叫**事件**。事件 A 的**对立事件** $\bar{A}$ 是"A 不发生"，满足 $A \cap \bar{A} = \varnothing$，$A \cup \bar{A} = \Omega$。

划分：一组事件 $A_1, \dots, A_n$ 两两互斥且并为 Ω，即"不重不漏"地把所有可能情况分成 n 类。全概率公式和贝叶斯定理都以划分为前提。例如"患病 / 健康"是一个二元划分，例 2 的"甲 / 乙 / 丙三条产线"是一个三元划分。

A.2　古典概型与概率的基本性质（对应 2、3 章）

古典概型：若试验只有有限个等可能的结果，则事件 A 的概率为

$$P(A) = \frac{A \text{ 包含的结果数}}{\text{全部结果数}}.$$

抛硬币、掷骰子、从袋中摸球、抽牌都属于此类。概率满足三条基本性质：

- 对任意事件 A：$0 \le P(A) \le 1$；必然事件 $P(\Omega) = 1$，不可能事件 $P(\varnothing) = 0$；
- **对立事件公式**：$P(\bar{A}) = 1 - P(A)$；
- **加法公式**：若 A、B 互斥，$P(A \cup B) = P(A) + P(B)$；一般情形 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$。

第三条中的互斥可加性是全概率公式推导（3.3 节第 2 步）的依据；对立事件公式在 4.1 节用于由 $P(H) = 0.001$ 得到 $P(\bar{H}) = 0.999$，在 6.2 节情形三用于求"传感器正常"的概率。

A.3　计数原理：加法、乘法与排列组合（对应 3.2 节、附录 B）

分类加法计数原理：完成一件事有 n 类互不重叠的办法，第 i 类有 m_i 种，则总办法数为 $m_1 + m_2 + \cdots + m_n$。

分步乘法计数原理：完成一件事需依次经过 n 步，第 i 步有 m_i 种办法，则总办法数为 $m_1 m_2 \cdots m_n$。例 1"两张都是 A"的计数（第一张 4 种、第二张 3 种，共 4×3 种有利结果）用的就是它。

排列：从 n 个不同元素中取 m 个排成一列，总数为

$$A_n^m = n(n-1)\cdots(n-m+1) = \frac{n!}{(n-m)!},$$

其中 $n! = n(n-1)\cdots 2 \cdot 1$ 叫 n 的阶乘（规定 $0! = 1$）。

组合：从 n 个不同元素中取 m 个、不计顺序，总数为

$$C_n^m = \binom{n}{m} = \frac{A_n^m}{m!} = \frac{n!}{m!\,(n-m)!}.$$

除以 $m!$ 是因为同一种选取有 $m!$ 种排法、只算一种组合。例 1 的方法二用到：从 52 张牌中任取 2 张，共有 $C_{52}^2 = \frac{52\times 51}{2} = 1326$ 种等可能结果；两张都是 A 的有 $C_4^2 = \frac{4\times 3}{2} = 6$ 种。

A.4　条件概率与事件的独立性（对应 3.1、5.1、6.1、6.2 节）

条件概率的定义 $P(A \mid B) = P(A \cap B)/P(B)$ 在 3.1 节已详述。与之对偶的概念是**独立性**：

> **定义 A（事件的独立性）**
> 若 $P(A \cap B) = P(A)\,P(B)$，称事件 A、B**相互独立**。由条件概率定义可知，这等价于 $P(A \mid B) = P(A)$（当 $P(B) > 0$）——即"B 的发生不影响 A 的概率"。

独立性是简化计算的核心假设：5.1 节的序贯更新要求前后两份证据独立；6.2 节的振动与温度传感器因物理原理不同而近似独立；6.1 节朴素贝叶斯用的是**条件独立**——"在给定类别（垃圾/正常）的条件下，词与词相互独立"，即 $P(W_i \cap W_j \mid S) = P(W_i \mid S)P(W_j \mid S)$。注意"无条件独立"与"条件独立"是两个不同的性质，不能互相推出。

A.5　数学期望与方差（初步）（对应 5.2、6.3、6.4 节）

设离散随机变量 X 取值为 $x_1, \ldots, x_n$，对应概率 $p_1, \ldots, p_n$（$\sum p_i = 1$）。

数学期望（均值）是取值按概率的加权平均：

$$E(X) = x_1 p_1 + x_2 p_2 + \cdots + x_n p_n.$$

期望的直觉是"长期平均"：重复试验很多次，结果的算术平均会趋近 $E(X)$。6.3 节"期望代价最小"的判决准则，就是把每种判决的代价按其后验概率加权平均后比较；6.4 节的"期望损失" $E[\max(\theta_A - \theta_B, 0)]$ 是同一个思想。

方差度量取值的分散程度：

$$\mathrm{Var}(X) = E\big[(X - E(X))^2\big] = E(X^2) - [E(X)]^2,$$

其算术平方根叫**标准差**。方差越小，随机变量越"确定"。图 1 中后验曲线越来越窄，用概率语言说就是 θ 的后验方差随数据量增大而减小——"越来越自信"的严格含义。

连续型随机变量（如 5.2、6.4 节的 θ）取值连续，不能说"取某个值的概率"（那是 0），改用**概率密度曲线**描述：曲线下某区间的面积 = θ 落入该区间的概率，曲线下总面积恒为 1。期望、方差的概念同样适用，只是把求和换成积分——本文不需要读者会算积分，看懂"曲线越高 = 可能性越大，曲线越窄 = 越确定"即可。

附录 B　练习题（附参考答案）

练习 1（基础公式）。某地区人群中，吸烟者占 25%，吸烟者患某病的概率为 12%，非吸烟者患该病的概率为 3%。随机抽一人，(a) 他患该病的概率是多少？(b) 若已知他患病，他是吸烟者的概率是多少？

参考答案。(a) 全概率公式：$P(B) = 0.12 \times 0.25 + 0.03 \times 0.75 = 0.03 + 0.0225 = 0.0525$。(b) 贝叶斯定理：$P(A \mid B) = \dfrac{0.12 \times 0.25}{0.0525} = \dfrac{0.03}{0.0525} \approx 57.1\%$。

练习 2（疾病筛查变式）。沿用 4.1 节的数据（患病率 0.1%，灵敏度 99%，误报率 1%）。某人在第一次筛查阳性后，又做了一次**相互独立**的同种化验，结果为阴性。求他患病的后验概率。（提示："阴性"的似然是 $P(\bar{E} \mid H) = 0.01$ 与 $P(\bar{E} \mid \bar{H}) = 0.99$。）

参考答案。以第一次的后验 0.0902 为新先验：

$$P(H \mid E_1 \bar{E}_2) = \frac{0.01 \times 0.0902}{0.01 \times 0.0902 + 0.99 \times 0.9098} = \frac{0.000902}{0.000902 + 0.9007} \approx 0.10\%.$$

一阳一阴后，后验几乎退回初始先验 0.1%——第二次阴性证据的强度（似然比 $0.01/0.99 \approx 1/99$）恰好抵消了第一次阳性（似然比 $0.99/0.01 = 99$）。

练习 3（朴素贝叶斯）。沿用 6.1 节表 6 的似然表与先验 $P(S) = 0.5$。一封邮件含"免费"、含"会议"、不含"中奖"、不含"发票"。它是垃圾邮件的后验概率是多少？

参考答案。逐项查表（含"会议"用出现列 $0.167/0.667$，不含"中奖"用不出现列 $0.500/0.833$）：

$$\text{后验比} = 1 \times \frac{0.667}{0.167} \times \frac{0.167}{0.667} \times \frac{0.500}{0.833} \times \frac{0.667}{0.667} \approx 4.0 \times 0.25 \times 0.60 \times 1.0 = 0.60.$$

后验 $= \dfrac{0.60}{1 + 0.60} = 37.5\% < 50\%$。**放行**——"会议"一词的证据（权重 0.25）压过了"免费"（权重 4.0）的一部分，体现了证据的双向作用。

练习 4（先验的作用）。6.2 节的泵机诊断中，若该泵已连续五年无故障、刚做过大修，你认为先验 $P(H) = 0.02$ 应该上调还是下调？用 $P(H) = 0.005$ 重算振动报警后的后验，并说明处置策略应如何变化。

参考答案。应下调，因为"刚大修 + 历史良好"是降低故障可能性的信息。重算：

$$P(H \mid E_1) = \frac{0.95 \times 0.005}{0.95 \times 0.005 + 0.05 \times 0.995} = \frac{0.00475}{0.00475 + 0.04975} \approx 8.7\%.$$

仍落在表 7 的"复检"区间，但比 27.9% 更靠近"观察"边界——同样的报警，处置等级可以相应降低。这正说明先验是贝叶斯方法中"领域知识"的入口。

参考文献

1. 盛骤, 谢式千, 潘承毅. *概率论与数理统计*（第四版）[M]. 北京: 高等教育出版社, 2008.
2. 教育部. *普通高中数学课程标准（2017 年版 2020 年修订）*[S]. 北京: 人民教育出版社, 2020.
3. Jaynes E T. *Probability Theory: The Logic of Science*[M]. Cambridge: Cambridge University Press, 2003.
4. Gelman A, Carlin J B, Stern H S, et al. *Bayesian Data Analysis*（3rd ed.）[M]. Boca Raton: CRC Press, 2013.
5. McGrayne S B. *The Theory That Would Not Die: How Bayes' Rule Cracked the Enigma Code, Hunted Down Russian Submarines, and Emerged Triumphant from Two Centuries of Controversy*[M]. New Haven: Yale University Press, 2011.