大模型发展史 · 关键文献

# 大模型关键30篇

## 论文与博客 · 学习卡片

从 Transformer 到推理模型：30 个改变方向的瞬间。
每张卡片给出核心结论、三条要点、影响判断与学习提示。


第 01 章 架构与范式 2017 - 2019

第 02 章 规模定律 2020 - 2022

第 03 章 对齐革命 2022

第 04 章 开放生态与效率 2021 - 2023

第 05 章 智能体与上下文 2022 - 2023

第 06 章 推理时代 2024 - 2025


一条主线

架构让规模可行，规模让能力跃迁；
对齐让能力可用，效率让能力可负担；
推理，让能力继续增长。

2017 Transformer
2019 GPT-2
2020 GPT-3
2022 ChatGPT
2024 o1
2025 R1

6 个篇章 · 30 张卡片 · 18 页

编制：DeepSeek Harness | 2026 年 10 月

CONTENTS

# 目录

按时间与主题编排：先看骨架如何搭起，再看规模、对齐、效率、智能体与推理如何层层推进。


## 第 01 章 架构与范式 2017 - 2019

注意力、双向编码与生成式预训练

01 Attention Is All You Need 3
抛弃循环与卷积：注意力就是你所需要的一切

02 BERT: Pre-training of Deep Bidirectional Transformers 3
把“预测下一个词”换成“完形填空”

03 Language Models are Unsupervised Multitask Learners 4
GPT-2：不做微调，一个语言模型包办多任务

04 Exploring the Limits of Transfer Learning with T5 4
把所有 NLP 任务改写成“文本进、文本出”

05 The Bitter Lesson 5
苦涩的教训：能随算力扩展的方法终将胜出

## 第 02 章 规模定律 2020 - 2022

参数、数据与算力的定量关系

06 Language Models are Few-Shot Learners 5
GPT-3：1750 亿参数，用“上下文”代替梯度更新

07 Scaling Laws for Neural Language Models 6
损失可以预测：语言模型的幂律缩放定律

08 Retrieval-Augmented Generation for Knowledge-Intensive NLP 6
RAG：把外部知识库接进生成模型

09 Switch Transformers: Scaling to Trillion Parameter Models 7
每次只激活一个专家：稀疏门控的万亿参数模型

10 Training Compute-Optimal Large Language Models 7
Chinchilla：大多数大模型其实“训练不足”

## 第 03 章 对齐革命 2022

让模型有用、诚实、无害

11 Training Language Models to Follow Instructions with Human Feedback 8
InstructGPT：1.3B 比 175B 更受人喜欢

12 Constitutional AI: Harmlessness from AI Feedback 8
宪法 AI：让模型自己批评并修正自己

13 Chain-of-Thought Prompting Elicits Reasoning in LLMs 9
思维链：让模型“想一步、说一步”

14 Emergent Abilities of Large Language Models 9
涌现：小模型为零、大模型突然可用的能力

15 Introducing ChatGPT 10
一个对话框，让一亿人第一次亲手用上大模型

## 第 04 章 开放生态与效率 2021 - 2023

权重开放、微调与推理工程

16 LLaMA: Open and Efficient Foundation Language Models 10
用更多数据、更小模型，逼近闭源巨头

17 GPT-4 Technical Report 11
不公布架构，只公布能力与风险

18 LoRA: Low-Rank Adaptation of Large Language Models 11
冻结原模型，只训练两个小矩阵

19 FlashAttention: Fast and Memory-Efficient Exact Attention 12
不改变数学结果，只改变显存访问顺序

20 Direct Preference Optimization: Your LM is Secretly a Reward Model 12
DPO：把 RLHF 化简成一个分类损失

21 Efficient Memory Management for LLM Serving with PagedAttention 13
vLLM：像操作系统一样管理 KV Cache

## 第 05 章 智能体与上下文 2022 - 2023

工具、检索与长上下文

22 ReAct: Synergizing Reasoning and Acting in Language Models 13
边想边做：推理与行动交替的智能体循环

23 Toolformer: Language Models Can Teach Themselves to Use Tools 14
模型自己学会“何时调用哪个 API”

24 Lost in the Middle: How Language Models Use Long Contexts 14
长上下文不是免费的：中间的信息最容易被忽略

25 Let's Verify Step by Step 15
奖励每一步推理，而不是只看最终答案

26 State of GPT 15
把 ChatGPT 的训练流水线一次讲透

## 第 06 章 推理时代 2024 - 2025

用强化学习与思考时间换智能

27 Learning to Reason with LLMs (o1) 16
让模型在回答前“想更久”

28 DeepSeek-V3 Technical Report 16
671B 参数、558 万美元：极致工程效率

29 DeepSeek-R1: Incentivizing Reasoning Capability via RL 17
不靠人类推理轨迹，纯强化学习也能学会长链思考

30 Welcome to the Era of Experience 17
下一代模型的数据，将来自“经验”而非人类文本

01 第 01 章 · 架构与范式

论文 2017 · NeurIPS

★★★★★

## Attention Is All You Need

抛弃循环与卷积：注意力就是你所需要的一切

Vaswani 等 · Google Brain / Google Research

> **只用注意力就能建模序列，而且比 RNN 训练得更快、更可并行。**

- **自注意力** 每个位置直接与全序列交互，任意两个 token 的路径长度为 1，长程依赖不再被逐步传递稀释。
- **多头与位置编码** 8 个头在不同子空间学习句法、指代与语义关系；正弦位置编码把顺序信息注入无序的注意力。
- **工程胜利** base 模型 8 块 P100 训练 3.5 天，WMT14 英德 BLEU 41.8，以更低训练成本刷新 SOTA。

**为什么关键** 今天几乎所有大模型的骨架：GPT、BERT、T5、Llama 都是它的变体。

**学习提示** 手推一遍 scaled dot-product attention 的矩阵维度，比读十遍公式更有用。

**自测** 为什么自注意力的路径长度是 O(1)？这对长文本意味着什么？

架构 · 自注意力 · 并行训练



02 第 01 章 · 架构与范式

论文 2018 · NAACL

★★★★★

## BERT: Pre-training of Deep Bidirectional Transformers

把“预测下一个词”换成“完形填空”

Devlin 等 · Google AI Language

> **双向编码器 + 掩码语言模型，一次预训练刷新 11 项 NLP 任务。**

- **掩码语言模型** 随机遮住 15% 的 token 让模型还原，迫使它同时利用左右两侧上下文，而不是只看前文。
- **预训练 + 微调** 预训练一次，下游任务只加一个分类头做微调，任务专用架构由此退出主流。
- **规模与结果** BERT-Large 3.4 亿参数、33 亿词语料，GLUE 平均分提升 7.7 分至 80.5%。

**为什么关键** 确立了“预训练 + 微调”的工业范式，NLP 从此进入统一模型时代。

**学习提示** 注意 BERT 是编码器，不擅长开放生成——理解与生成的分野从这里开始。

**自测** BERT 为什么必须遮住 token，而不能像 GPT 一样只看左侧？

预训练 · 双向编码 · 微调

03 第 01 章 · 架构与范式

论文 2019 · OpenAI 技术报告

★★★★★

## Language Models are Unsupervised Multitask Learners

GPT-2：不做微调，一个语言模型包办多任务

Radford 等 · OpenAI

> 15 亿参数的语言模型，不做任何微调就能翻译、摘要、答题。

- **零样本多任务** 把任务写成自然语言提示，下一个词预测的目标本身就隐含了多任务学习。
- **WebText 语料** 从 Reddit 高赞外链抓取 800 万文档、约 40GB 文本，强调数据质量而非数量。
- **分阶段发布** 以“担心滥用”为由先放出小模型再放大的，引发持续数年的开放与安全之争。

**为什么关键** 第一次让“scaling + 通用生成”成为路线共识，也是 GPT 系列神话的起点。

**学习提示** 复现 GPT-2 small（124M）是理解 decoder-only 训练循环的最佳练手项目。

**自测** GPT-2 的零样本能力来自哪里——微调，还是别的机制？

零样本 · 生成式 · 数据



04 第 01 章 · 架构与范式

论文 2019 · JMLR

★★★★☆

## Exploring the Limits of Transfer Learning with T5

把所有 NLP 任务改写成“文本进、文本出”

Raffel 等 · Google Research

> 一个模型、一套损失、一个解码器，统一所有文本任务。

- **统一框架** 分类、翻译、摘要甚至回归全部转成 seq2seq，用任务前缀区分，无需改动模型结构。
- **C4 语料** 清洗 750GB Common Crawl 得到 C4，成为后续预训练数据工程的模板。
- **系统对照** 在同算力下比较编码器-解码器、纯解码器、纯编码器，给出可复用的实证结论。

**为什么关键** “text-to-text”抽象影响了此后所有统一多任务模型与指令微调格式。

**学习提示** 精读它的消融实验部分，是学习“如何做严谨规模化对照实验”的范本。

**自测** T5 如何用一个模型同时做分类和生成？

统一框架 · seq2seq · 数据工程

05 第 01 章 · 架构与范式

博客 2019 · Rich Sutton 个人博客

★★★★★

## The Bitter Lesson

苦涩的教训：能随算力扩展的方法终将胜出

Richard S. Sutton · DeepMind / 阿尔伯塔大学

> **从长远看，能随算力扩展的通用方法，总会打败依赖人类知识的精巧方法。**

- **两类方法** 一类把人类知识写进系统，一类让搜索与学习自己发现规律；历史反复证明后者获胜。
- **历史证据** 国际象棋、围棋、语音识别、计算机视觉——每次都是“算力 + 通用学习”后来居上。
- **方法论推论** 不要给模型堆太多先验，要设计可扩展的学习算法与通用接口。

**为什么关键** 预训练与 scaling law 时代最重要的方法论宣言，解释了“大力出奇迹”并非运气。

**学习提示** 与 Chinchilla 对照读：scaling 有效，但“怎么分配算力”同样决定成败。

**自测** 如果算力继续增长，哪些“人类先验”反而会成为瓶颈？

方法论 · scaling · 思想



06 第 02 章 · 规模定律

论文 2020 · NeurIPS

★★★★★

## Language Models are Few-Shot Learners

GPT-3：1750 亿参数，用“上下文”代替梯度更新

Brown 等 · OpenAI

> **不更新任何权重，只靠提示里的几个示例，模型就能学会新任务。**

- **上下文学习** 零样本、单样本、少样本三种设定，性能随示例数量上升，无需任何参数更新。
- **规模跃迁** 96 层、12288 维、1750 亿参数、3000 亿 token，训练算力比 GPT-2 高两个数量级。
- **涌现能力** 翻译、算术、写代码、造句等未被显式训练的任务，在足够规模后突然可用。

**为什么关键** 定义了“基础模型”的产品形态：一个 API 服务所有任务，提示词成为新接口。

**学习提示** 重点看 few-shot 曲线与错误分析，理解“提示”为什么是一种新的编程范式。

**自测** 上下文学习与微调的本质区别是什么？

少样本 · 涌现 · 基础模型

07 第 02 章 · 规模定律

论文 2020 · arXiv / OpenAI

★★★★★

## Scaling Laws for Neural Language Models

损失可以预测：语言模型的幂律缩放定律

Kaplan 等 · OpenAI

> **损失随参数量、数据量、算力呈平滑幂律下降，大模型的表现可以被提前预测。**

- **三条幂律** L(N)、L(D)、L(C) 在多个数量级上近似直线，对数坐标下几乎不弯。
- **算力分配** 固定算力时模型与数据应同步放大；其“参数优先”的结论后来被 Chinchilla 修正。
- **可预测性** 用小模型的曲线外推大模型，训练开始前就能估算最终 loss。

**为什么关键** 让“要不要花一千万美元训一个大模型”从赌博变成工程决策。

**学习提示** 会画 log-log 图、会拟合幂律指数，是读懂所有 scaling 论文的基本功。

**自测** 按幂律，参数量翻 10 倍时 loss 大致如何变化？

幂律 · 算力 · 可预测性



08 第 02 章 · 规模定律

论文 2020 · NeurIPS

★★★★★

## Retrieval-Augmented Generation for Knowledge-Intensive NLP

RAG：把外部知识库接进生成模型

Lewis 等 · Facebook AI Research

> **参数记忆负责语言能力，非参数记忆负责事实知识，各司其职。**

- **架构** DPR 检索 top-k 文档，BART 以文档为条件生成，检索器与生成器端到端联合训练。
- **三大优势** 知识可更新（重建索引即可）、答案可溯源、显著降低事实性幻觉。
- **结果** 开放域问答刷新 SOTA，在少样本场景下优势更加明显。

**为什么关键** 企业落地大模型最主流的架构，今天所有“检索 + 生成”系统都源于此。

**学习提示** RAG 的瓶颈通常在检索而非生成——切块策略与召回评估决定效果上限。

**自测** RAG 中“参数记忆”和“非参数记忆”各负责什么？

检索增强 · 知识 · 落地

09 第 02 章 · 规模定律

论文 2021 · JMLR

★★★★☆

## Switch Transformers: Scaling to Trillion Parameter Models

每次只激活一个专家：稀疏门控的万亿参数模型

Fedus、Zoph、Shazeer · Google Brain

> 用 top-1 路由把参数量推到 1.6 万亿，而单 token 计算量几乎不变。

- **Top-1 路由** 每个 token 只经过一个专家，计算量与专家总数解耦，参数量可以独立扩张。
- **容量与均衡** 容量因子、token 丢弃与辅助负载均衡损失，是 MoE 能否训起来的关键工程。
- **结果** 同等算力下预训练速度提升约 7 倍，Switch-C 达到 1.6T 参数。

为什么关键 MoE 成为“用参数换质量、成本不线性上涨”的主流路线，Mixtral 与 DeepSeek 均沿用。

**学习提示** 读懂 expert capacity、token dropping、aux loss 三件事，MoE 就懂了一半。

自测 为什么 top-1 路由能用 1.6T 参数却不炸算力?

MoE · 稀疏激活 · 路由



10 第 02 章 · 规模定律

论文 2022 · NeurIPS

★★★★★

## Training Compute-Optimal Large Language Models

Chinchilla：大多数大模型其实“训练不足”

Hoffmann 等 · DeepMind

> 70B 参数配 1.4T token，用同样的算力打败了 280B 的 Gopher。

- **计算最优** 给定算力，参数量与训练 token 数应同比增加，约每个参数配 20 个 token。
- **实证** Chinchilla 70B / 1.4T token，在相同训练算力下全面超过 Gopher 280B。
- **行业纠偏** 此前“参数越大越好”的做法被证明是算力分配失衡，数据侧被长期低估。

为什么关键 直接改变了 Llama 等模型的数据策略，让“数据质量与数量”成为第一性问题。

**学习提示** 记住结论的边界：它不计推理成本——服务型产品仍偏爱“小模型 + 多数据”。

自测 Chinchilla 的 20 token/参数，对今天的推理服务还成立吗?

计算最优 · 数据配比 · 效率

11 第 03 章 · 对齐革命

论文 2022 · NeurIPS

★★★★★

## Training Language Models to Follow Instructions with Human Feedback

InstructGPT：1.3B 比 175B 更受人喜欢

Ouyang 等 · OpenAI

> **对齐比规模更划算：小模型经过人类反馈训练，输出比大模型更符合意图。**

- **三步流水线** 人类示范做 SFT → 人类排序训练奖励模型 → PPO 优化策略，即 RLHF 标准流程。
- **结果** 1.3B 的 InstructGPT 人类偏好胜率高于 175B GPT-3，幻觉与毒性同时下降。
- **目标函数化** 把“有用、诚实、无害”从口号变成可优化的奖励信号。

为什么关键 ChatGPT 的直接技术前身，RLHF 从此成为大模型对齐的标准流水线。

> **学习提示** 奖励模型只是代理目标，过度优化会 reward hacking——这是对齐的核心难题。

> 自测 RLHF 三步中，哪一步最容易出现 reward hacking?

RLHF · 指令微调 · 对齐



12 第 03 章 · 对齐革命

论文 2022 · arXiv / Anthropic

★★★★☆

## Constitutional AI: Harmlessness from AI Feedback

宪法 AI：让模型自己批评并修正自己

Bai 等 · Anthropic

> **用一份书面原则替代大量人类标注，让 AI 自己判断什么是有害的。**

- **SL-CAI** 模型按宪法原则自我批评并改写回答，再用改写后的数据做监督微调。
- **RL-CAI** 由 AI 依据原则对成对回答排序，代替人类偏好标注，即 RLAIF。
- **结果** 无害性接近 RLHF，同时把标注成本与尺度瓶颈大幅压低。

为什么关键 开启“可扩展监督 / AI 反馈”路线，也是 Claude 系列的方法论基础。

> **学习提示** 宪法条款就是产品价值观的代码化——读条款比读损失函数更能理解模型行为。

> 自测 宪法 AI 用 AI 替代人类标注，代价是什么?

对齐 · RLAIF · 可扩展监督

13 第 03 章 · 对齐革命

论文 2022 · NeurIPS

★★★★★

## Chain-of-Thought Prompting Elicits Reasoning in LLMs

思维链：让模型“想一步、说一步”

Wei 等 · Google Brain

> **只要在示例里写出推理步骤，模型的数学能力就会大幅跃升。**

- **少样本思维链** 8 个带推理过程的示例，PaLM 540B 在 GSM8K 上从 17.9% 提升到 56.9%。
- **规模依赖** CoT 的收益随模型规模出现，小模型照抄推理链反而可能被带偏。
- **零样本变体** 一句“Let's think step by step”即可触发分步推理。

**为什么关键** 推理模型时代的思想起点；今天的 test-time compute 本质是把 CoT 训进模型。

> **学习提示** CoT 输出不等于真实推理过程——可解释性与忠实性必须分开评估。

> **自测** 为什么 CoT 的收益主要出现在大模型上？

推理 · 提示 · 涌现



14 第 03 章 · 对齐革命

论文 2022 · TMLR

★★★★☆

## Emergent Abilities of Large Language Models

涌现：小模型为零、大模型突然可用的能力

Wei 等 · Google / DeepMind 等

> **有些能力在小模型上几乎为零，跨过某个规模阈值后突然出现。**

- **定义** 从随机水平跃迁到远高于随机，且无法由小模型的曲线外推。
- **证据** BIG-Bench 137 项任务中出现大量“相变”式曲线。
- **争议** 2023 年 Schaeffer 等指出：改用连续指标后“涌现”可能消失，部分是度量造成的假象。

**为什么关键** 塑造了“规模会带来质变”的信念，也迫使社区更严谨地定义“能力”。

> **学习提示** 务必连同反驳一起读——这是学习“指标如何制造结论”的绝佳案例。

> **自测** 如果“涌现”部分是度量假象，我们该如何评估能力？

涌现 · 评测 · 争议

15 第 03 章 · 对齐革命

博客 2022 · OpenAI 官方博客

★★★★★

## Introducing ChatGPT

一个对话框，让一亿人第一次亲手用上大模型

OpenAI

> **技术上并非突破，却是大模型从论文走向大众的转折点。**

- **产品化** 把 GPT-3.5 与 RLHF 包装成免费对话界面，5 天用户破百万。
- **交互范式** 自然语言成为界面，提示词工程随之成为一项新技能。
- **行业引爆** 微软、谷歌、Meta 全线跟进，AI 进入“iPhone 时刻”的叙事。

**为什么关键** 改变了整个产业的节奏：模型能力第一次被普通人直接感知。

**学习提示** 复盘它的成功公式：能力 × 易用性 × 免费，三者缺一不可。

**自测** ChatGPT 真正的技术突破发生在哪一年？

产品 · 拐点 · 交互



16 第 04 章 · 开放生态与效率

论文 2023 · arXiv / Meta AI

★★★★★

## LLaMA: Open and Efficient Foundation Language Models

用更多数据、更小模型，逼近闭源巨头

Touvron 等 · Meta AI

> **7B – 65B 全系用 1.4T token 训练，13B 在多数基准上超过 GPT-3 175B。**

- **数据策略** 小模型也“训饱”：所有尺寸都用 1.4T token，推理成本因此大幅下降。
- **结果** LLaMA-13B 多数基准超过 GPT-3 175B，65B 接近 Chinchilla-70B。
- **生态效应** 权重泄露后催生 Alpaca、Vicuna 与 Llama 2/3，点燃整个开源社区。

**为什么关键** 开源大模型的分水岭；没有 LLaMA 就没有今天的本地化与微调生态。

**学习提示** 它真正的贡献是“配方公开”——数据配比与训练细节比权重更值钱。

**自测** LLaMA 为什么要给 7B 模型也喂 1.4T token?

开源 · 数据 · 生态

17 第 04 章 · 开放生态与效率

论文 2023 · OpenAI 技术报告

★★★★★

## GPT-4 Technical Report

不公布架构，只公布能力与风险

OpenAI

> 大模型进入“黑箱 + 系统卡”时代：能力评估与安全评估同时披露。

- **多模态** 接受图像与文本输入，模拟律师资格考试进入前 10%，MMLU 达 86.4%。
- **可预测扩展** 用 1/1000 算力的小模型预测大模型最终性能，把训练变成可规划工程。
- **安全工程** 红队测试、RLHF、可解释性、部署前评估，构成完整的系统卡范式。

为什么关键 把“技术报告”变成“能力 + 风险”双披露的行业模板。

**学习提示** 报告里最值得学的是评估设计，而不是那些跑分数字。

自测 GPT-4 报告“信息更少”为何反而影响更大?

多模态 · 评估 · 安全



18 第 04 章 · 开放生态与效率

论文 2021 · ICLR

★★★★★

## LoRA: Low-Rank Adaptation of Large Language Models

冻结原模型，只训练两个小矩阵

Hu 等 · 微软

> 用不到 1% 的可训练参数完成微调，效果与全量微调相当。

- **低秩假设** 权重更新分解为 $\Delta W = BA$，秩 r 远小于维度，可训练参数降低约一万倍。
- **工程收益** 显存需求降 3 倍，单卡即可微调 175B 模型，适配器可插拔切换。
- **结果** GPT-3 175B 上效果与全量微调相当或更好，且不增加推理延迟。

为什么关键 让“人人可微调”成为现实，是开源生态繁荣的关键基础设施。

**学习提示** rank 与 alpha 的配比、目标模块的选择，比学习率更影响最终效果。

自测 LoRA 的低秩假设，在什么情况下会失效?

微调 · 低秩 · 效率

19 第 04 章 · 开放生态与效率

论文 2022 · NeurIPS

★★★★★

## FlashAttention: Fast and Memory-Efficient Exact Attention

不改变数学结果，只改变显存访问顺序

Dao 等 · 斯坦福大学

> **注意力提速 2 – 4 倍、显存节省 5 – 20 倍，而且结果是精确的。**

- **IO 感知** 把 Q/K/V 分块载入 SRAM，避免与 HBM 之间反复搬运大矩阵。
- **重计算** 反向传播时重算注意力矩阵，用算力换显存，突破长序列瓶颈。
- **结果** BERT 训练提速 15%，GPT-2 提速 3 倍，使长上下文训练成为可能。

**为什么关键** 长上下文与大规模训练的前提工程，今天几乎所有推理框架都内置它。

**学习提示** 读这篇能建立“瓶颈常在显存带宽而非 FLOPs”的系统直觉。

**自测** FlashAttention 没有减少 FLOPs，为什么还能更快?

系统 · 注意力 · 显存



20 第 04 章 · 开放生态与效率

论文 2023 · NeurIPS

★★★★★

## Direct Preference Optimization: Your LM is Secretly a Reward Model

DPO：把 RLHF 化简成一个分类损失

Rafailov 等 · 斯坦福大学

> **无需奖励模型、无需在线采样，直接用偏好对训练策略。**

- **数学洞察** RLHF 的最优策略有闭式解，奖励可隐式表达为策略与参考模型的比值。
- **算法** 只对 (chosen, rejected) 偏好对做二分类，训练稳定、实现简单。
- **结果** 在情感控制、摘要、对话上匹配或超过 PPO，成本大幅降低。

**为什么关键** 大幅降低对齐门槛，DPO 及其变体成为开源模型后训练的主流选择。

**学习提示** 隐式奖励可能过拟合偏好数据，$\beta$ 与数据质量是真正的关键超参。

**自测** DPO 为什么可以不要奖励模型?

对齐 · 偏好优化 · 简化

21 第 04 章 · 开放生态与效率

论文 2023 · SOSP

★★★★★

## Efficient Memory Management for LLM Serving with PagedAttention

vLLM：像操作系统一样管理 KV Cache

Kwon 等 · UC 伯克利

> **用分页思想消除显存碎片，推理吞吐提升 2 – 4 倍。**

- **问题** KV Cache 按最大长度预留，实际浪费 60% - 80% 的显存。
- **方案** 分页 + 块表，按需分配，并支持并行采样、beam search 的块共享。
- **结果** 同等延迟下吞吐提升 2 - 4 倍，成为开源推理服务的事实标准。

为什么关键 把“模型能力”变成“可负担的 token 成本”，是 LLM 规模化的最后一公里。

> **学习提示** 推理优化三件事：KV Cache、批处理调度、量化——这篇讲透了第一件。

> 自测 PagedAttention 解决的是显存容量还是显存碎片？

推理 · KV Cache · 服务



22 第 05 章 · 智能体与上下文

论文 2022 · ICLR

★★★★★

## ReAct: Synergizing Reasoning and Acting in Language Models

边想边做：推理与行动交替的智能体循环

Yao 等 · 普林斯顿大学 / Google

> **让模型交替“思考”和“行动”，边调用工具边根据结果修正。**

- **循环结构** Thought → Action → Observation，直到任务完成或达到步数上限。
- **结果** ALFWorld 成功率提升 34%，WebShop 提升 10%，推理轨迹可读可审计。
- **对比** 纯 CoT 容易幻觉，纯行动缺乏规划；ReAct 把二者接成一个闭环。

为什么关键 现代 Agent 的基础循环，LangChain、AutoGPT 等框架的默认范式。

> **学习提示** 工具返回值的格式稳定性，往往比提示词技巧更决定 Agent 成败。

> 自测 ReAct 的“观察”环节，为什么对减少幻觉关键？

Agent · 工具 · 推理

23 第 05 章 · 智能体与上下文

论文 2023 · NeurIPS

★★★★☆

## Toolformer: Language Models Can Teach Themselves to Use Tools

模型自己学会“何时调用哪个 API”

Schick 等 · Meta AI

> **无需人工标注调用数据，模型通过自监督学会在文本中插入 API 调用。**

- **自监督筛选** 让模型生成候选调用，实际执行后按“是否降低后续 loss”保留有用调用。
- **工具集** 计算器、问答、搜索、翻译、日历 5 种工具，覆盖常见外部能力。
- **结果** 多项任务超过同规模基线，且不损害原有语言建模能力。

为什么关键 工具学习从“提示工程”走向“训练目标”，是 Agent 能力内化的关键一步。

**学习提示** 注意局限：调用是单步的，没有多步规划与错误恢复。

自测 Toolformer 如何判断一次 API 调用“有用”？

工具学习 · 自监督 · Agent



24 第 05 章 · 智能体与上下文

论文 2023 · TACL

★★★★☆

## Lost in the Middle: How Language Models Use Long Contexts

长上下文不是免费的：中间的信息最容易被忽略

Liu 等 · 斯坦福大学

> **关键信息放在长文档中间时，模型表现显著下降，甚至低于没有上下文。**

- **U 形曲线** 信息位于开头或结尾时准确率高，位于中间时最低，跨模型一致出现。
- **实验** 多文档问答、键值检索、长文档排序三类任务均复现该现象。
- **启示** 加长窗口 ≠ 有效利用；需要重排序、分段与显式引用。

为什么关键 长上下文竞赛中最重要的“泼冷水”论文，直接影响了 RAG 与上下文工程。

**学习提示** 做长文档应用时，把最关键的信息放在开头或结尾，是最便宜的优化。

自测 上下文窗口变大后，为什么 RAG 仍然必要？

长上下文 · 评测 · RAG

25 第 05 章 · 智能体与上下文

论文 2023 · ICLR

★★★★☆

## Let's Verify Step by Step

奖励每一步推理，而不是只看最终答案

Lightman 等 · OpenAI

> **过程监督让模型学会更可靠的思考，而不只是猜对答案。**

- **过程监督** 人工标注 80 万步推理（PRM800K），训练逐步打分的过程奖励模型。
- **结果** MATH 子集上 78.2% vs 结果监督 72.4%，并可用于搜索与重排序。
- **泛化** 过程奖励在分布外问题上更稳健，错误定位也更精确。

**为什么关键** 推理模型“过程奖励 + 搜索”路线的先声，o1 与 R1 的思想源头之一。

**学习提示** 过程标注昂贵但可复用，是高质量推理数据资产的典型形态。

**自测** 过程监督比结果监督多标注了什么？

推理 · 过程监督 · 奖励模型



26 第 05 章 · 智能体与上下文

博客 2023 · Microsoft Build 演讲

★★★★☆

## State of GPT

把 ChatGPT 的训练流水线一次讲透

Andrej Karpathy · OpenAI（时任）

> **预训练、监督微调、奖励建模、RLHF——四步拆解，人人都能听懂。**

- **流水线** Base model → SFT → RM → RL，每一步的数据来源与典型失败模式。
- **实践建议** 提示技巧、工具使用、RAG 的适用边界与常见误区。
- **影响** 成为工程师理解 ChatGPT 内部机制最流行的入门材料。

**为什么关键** 最好的技术传播样本：把前沿论文压缩成可操作的工程心智模型。

**学习提示** 配合 GPT-4 系统卡读，能看清“能力”与“对齐”两条线的分工。

**自测** Karpathy 四步流水线中，SFT 与 RLHF 各解决什么问题？

科普 · 训练流程 · 工程

27 第 06 章 · 推理时代

博客 2024 · OpenAI 官方博客

★★★★★

## Learning to Reason with LLMs (o1)

让模型在回答前“想更久”

OpenAI

> **推理能力可以随思考时间继续提升——scaling 从训练延伸到推理。**

- **新范式** 用大规模强化学习训练模型生成内部思维链，再用 test-time compute 扩展。
- **结果** AIME 83%、Codeforces 第 89 百分位、GPQA 博士级科学题超过人类专家。
- **代价** 延迟与成本显著上升，催生按“思考 token”计费的新产品形态。

**为什么关键** 开启“推理即服务”时代，把 scaling law 从训练阶段延伸到推理阶段。

**学习提示** 思考时间不是越长越好——存在收益递减，需要与任务难度匹配。

**自测** o1 把 scaling 延伸到了哪个新维度?

推理 · test-time compute · 产品



28 第 06 章 · 推理时代

论文 2024 · arXiv / DeepSeek

★★★★★

## DeepSeek-V3 Technical Report

671B 参数、558 万美元：极致工程效率

DeepSeek-AI

> **671B 总参数、37B 激活，用 278.8 万 H800 卡时完成训练。**

- **MoE 架构** 细粒度专家 + 共享专家，无辅助损失的负载均衡策略，避免传统 MoE 的性能折损。
- **训练创新** FP8 混合精度、DualPipe 流水线并行、多 token 预测（MTP）共同压低成本。
- **结果** MMLU 88.5，数学与代码接近闭源第一梯队，训练成本低一个数量级。

**为什么关键** 证明“极致工程效率”可以弥补算力差距，重塑了全球训练成本认知。

**学习提示** 重点读并行策略与 FP8 方案——这是工程复现价值最高的部分。

**自测** DeepSeek-V3 的低成本，主要来自算法还是工程?

MoE · 训练效率 · 开源

29

第 06 章 · 推理时代

论文 2025 · Nature 封面论文

★★★★★

## DeepSeek-R1: Incentivizing Reasoning Capability via RL

不靠人类推理轨迹，纯强化学习也能学会长链思考

DeepSeek-AI

> **仅用规则奖励做强化学习，模型自发出现自我验证与反思。**

- **R1-Zero** 直接对基座模型做 GRPO 强化学习，奖励只看答案正确性与格式。
- **R1 多阶段** 冷启动长 CoT 数据 + 拒绝采样 + 全场景 RL，兼顾可读性与通用能力。
- **结果** AIME 2024 79.8%、MATH-500 97.3%、Codeforces 第 96.3 百分位，权重开源。

**为什么关键** 第一次公开证明“纯 RL 推理”可行，把推理模型从黑箱变成可复现的配方。

> **学习提示** 关注奖励设计（规则 vs 神经奖励）与长度控制——这是复现的关键。

> **自测** R1-Zero 没有人类推理数据，规则奖励如何避免“学歪”？

强化学习 · 推理 · 开源



30

第 06 章 · 推理时代

论文 2025 · arXiv 预印本

★★★★☆

## Welcome to the Era of Experience

下一代模型的数据，将来自“经验”而非人类文本

David Silver、Richard Sutton · DeepMind / 阿尔伯塔大学

> **人类数据正接近枯竭，持续的环境交互经验才是通向超人的关键。**

- **核心论点** 预训练依赖的人类文本有限，智能体在环境中产生的流式经验可以无限增长。
- **关键要素** 长时程规划、来自环境的奖励、探索与元学习、持续学习。
- **待解难题** 灾难性遗忘、奖励作弊、安全性与可验证性。

**为什么关键** 为“后预训练时代”给出最清晰的研究议程，深刻影响 Agent 与 RL 路线。

> **学习提示** 与“数据墙”讨论对照读：哪些能力仍能靠文本学会，哪些必须靠交互。

> **自测** “经验时代”与预训练时代的核心差别是什么？

经验学习 · Agent · 前沿

HOW TO USE

# 如何使用这套卡片

30 张卡片不是 30 个孤立知识点，而是六条相互咬合的线索。按路径读，比按编号读更有效。

## A 架构与规模线

先懂模型怎么搭起来、为什么越大越强

01 02 03 06 07 10 16 18 20

## B 对齐与产品线

从“会说话”到“听得懂、靠得住、用得上”

11 12 15 17 19 26 25

## C 推理与智能体线

让模型会用工具、会规划、会想更久

13 14 22 23 24 27 28 29 30

## 如果只有一小时，先读这五篇

| | | |
|---|---|---|
| 01 | Attention Is All You Need | 看懂所有大模型的共同骨架 |
| 06 | Language Models are Few-Shot Learners | 理解“上下文学习”为何是范式转折 |
| 10 | Training Compute-Optimal Large Language Models | 纠正“参数越大越好”的直觉 |
| 11 | Training Language Models to Follow Instructions with Human Feedback | 看清对齐如何把能力变成产品 |
| 29 | DeepSeek-R1: Incentivizing Reasoning Capability via RL | 理解纯强化学习为何能长出推理 |

## 30 篇之外 · 值得补读

2022 **PaLM** 540B 规模与 CoT 涌现的实证

2023 **Mamba** 状态空间模型对注意力的挑战

2024 **Llama 3** 数据配比与合成数据的规模化

2023 **Mixtral** 开源稀疏 MoE 的工程样板

2024 **Gemini 1.5** 百万级上下文的系统设计

2024 **Claude 3** 模型卡与安全评估的范式

## 术语速查

**Scaling Law** 损失随参数、数据、算力呈幂律下降，可提前预测。

**MoE** 多专家稀疏激活，参数扩容而单 token 计算量近似不变。

**Test-time compute** 推理时多“想”一会儿，用思考 token 换质量。

**RLHF** 用人类偏好训练奖励模型，再用强化学习优化策略。

**KV Cache** 缓存历史键值，避免自回归解码时重复计算。

**过程监督** 对推理的每一步给奖励，而不是只看最终答案。

**关于星级** ★★★★★ 表示开创范式或定义方向，★★★★☆ 表示关键支撑或重要纠偏；它综合了原创性、后续影响与产业渗透，不是引用数排名。

**关于事实** 参数、跑分、成本等数字取自论文摘要、官方技术报告或博客原文；不同评测设置下数值可能略有差异。

**关于读法** 每张卡片先读引文，再扫三条要点；遇到不熟悉的术语，回到对应论文的摘要与方法图，通常十分钟即可建立印象。

“The bitter lesson is that the actual contents of minds are tremendously, irredeemably complex.”

— Richard S. Sutton, 2019